



AI 프레임워크를 이용한 유한요소해석 데이터를 기반으로 한 솔더 조인트 수명 모델

모하드 주바이어 아크타르 *, 맥시밀리안 슈미드, 안드레아스 엘리우스, 골든 엘거

초 록

전자 시스템의 열-기계 신뢰성은 솔더 조인트 내에서 균열 성장에 의해 종종 제한받는다. 이 문제를 해결하기 위해서는 패키지 및 솔더 패드 설계에 주의 깊게 고려해야 한다. 유한요소해석(Finite Element Analysis, FEA)은 균열 성장을 예측하고 그 수명을 모델링하는 데 널리 사용된다. 전통적으로 FEA 후처리 방법은 인간의 전문 지식에 의존하여 플라스틱 및 크립 변형률이 중요한 위치에서 평가할 적절한 영역을 선택하고, Coffin-Manson 방정식을 사용하여 실험 데이터와 상관관계를 구축하는데, 이 방법은 주기적 플라스틱 변형률에 기반하여 피로 수명을 예측한다. 본 연구는 인공지능을 활용한 표면 부착 장치(Surface-Mounted Device, SMD)의 PCB(Printed Circuit Board) 상에서 FEA 후처리 방법을 소개하며, 이 방법은 FEA 데이터를 크립 변형률 값의 2D 그리드 맵으로 변환하고 Convolutional Neural Network(CNN)을 사용하여 자동 특징 추출을 수행한다. 그 다음 완전 연결 계층이 추출된 특징과 실험 측정된 솔더 조인트 수명 사이의 비선형 관계를 효과적으로 포착한다.

이 연구는 자동차 산업에서 헤드라이트에 사용되는 세라믹 기반 고효율 LED 패키지의 솔더 인터커넥츠에서 균열 형성 개념을 개발하는 데 중점을 두고 있다. 검증된 FEA 모델은 1800개의 LED 패키지를 포함한 광범위한 데이터 세트를 기반으로 하며, 이는 세라믹 기반 LED 패키지 7가지 유형과 솔더 5종류를 포함한다. 세라믹 LED 패키지 설계는 솔더링을 위한 두 개의 패드와 세 개의 패드 풋프린트, 얇은 필름 및 두꺼운 필름 메탈라이즈드 세라믹 캐리어를 포함한다. 결과는 시뮬레이션과 실험 데이터 간에 강한 일치(R^2 점수 99.867%)가 있음을 보여준다. 이 FEA 데이터에서 자동 특징 추출은 솔더 신뢰성 예측을 개선하는 새로운 기준을 설정하며, 솔더 조인트 수명 예측에 있어 기존 방법보다 더 우수함을 입증하였다.

고효율 LED 기술은 장수명을 보장하고 과열을 방지하기 위해 견고한 열 관리와 패키징이 요구된다. 열기계적 신뢰성은 패키지 재료의 변하는 열팽창 계수가 솔더 점착부에 스트레스와 균열을 일으켜 파손을 유발할 수 있으므로 매우 중요하다. 유한요소해석(Finite Element Analysis, FEA)은 구성 모델을 사용하여 솔더 점착부의 수명을 모델링하는 널리 사용되는 접근 방식으로, 솔더 점착부 파손에 이르는 스트레스, 크리프, 그리고 플라스틱 변형을 상세하게 시뮬레이션할 수 있다.

수명을 평가하기 위해 외부 솔더 공의 플라스틱 변형률을 측정하고, 솔더 공의 작은 영역을 추출하여 인터페이스에서 평균 값을 계산합니다. 이 작업은 25- μ m 두께의 솔더층에서 수행됩니다. 수집된 데이터는 수명 데이터와 Weibull 분포를 사용해 상관분석을 진행하여 평가합니다 [1-9]. 그러나 유한요소해석(Finite Element Analysis, FEA) 접근법은 SMD 세라믹 LED 패키지에 대해 잘 확립되어 있지 않습니다. BGA와 달리 SMD는 크기와 모양이 다른 접촉 영역과 고유한 응력 프로파일을 가지고 있습니다. 설계 변동성이 큰 SMD 패키지, 예를 들어 세라믹 LED 패키지의 패드 레이아웃, 다양한 두께의 세라믹 및 세라믹 위의 구리 메탈라이제이션과 같은 요소는 일반화된 후처리 기술을 요구합니다. 이를 통해 결과를 캡처하고 분석하며 수명 모델을 정확하게 맞춥니다. Shaygi 등 [10]은 Wunderle [11]이 제안한 10% 균열 길이 적분 면적 방법에 기반한 파절 기준을 적용하여 단일 LED 구성에 집중함으로써 이 방향에서 중요한 진전을 이루었습니다.

SMD 장치의 평가는 아직 발전 중이며, 수명 예측을 위한 크리프 변형률을 사용한 표준화된 유한요소해석(Finite Element Analysis, FEA) 기준이 부족합니다. 몇몇 연구에서는 신경망과 FEA 데이터를 통합하여 BGA의 솔더 조인트 수명을 예측하는 방법을 탐구했습니다. 연구자들은 인공신경망(ANNs)을 유한요소해석(FEA)과 결합하여 사용하였습니다. 예를 들어, Subbarayan과 Mahajan은 FEA와 물리-신경망 접근법을 사용하여 솔더 조인트 신뢰성을 모델링하였으며, 이는 솔더 조인트 부피, 높이 및 패드 크기 등의 요소를 고려하였습니다 [12]. Qasaimeh 등은 동온 피로 시험 중 무도질 자유롭게 솔더 조인트의 피로 균열 성장 패턴을 연구하기 위해 ANN 모델을 개발하였습니다 [13]. Sung 등은 신경망을 사용한 솔더 조인트 신뢰성 평가가 훈련 데이터 세트가 충분히 포괄적이고 정확할 경우 매우 정확한 결과를 얻을 수 있다고 주장하였습니다 [14]. Z. Zhao는 칩 두께, 솔더 조인트 구성 및 PCB 두께의 변화를 고려하여 BGA의 피로 수명을 크리프 변형률 데이터를 사용해 예측하였습니다 [15]. Samavatian 등 Samavatian 등은 재료 특성, 열 부하 및 솔더 기하학을 고려하여 BGA의 피로 수명을 평가하기 위한 상관관계 주도 신경망(Correlation-Driven Neural Network, CDNN)을 도입하였으나, 기하학이 피로에 미치는 영향이나 주요 요인들(예: 정지 온도 및 경사율)은 검토하지 않았다. 또한 평균 변형 에너지 값을 통합하여 얇은 솔더 조인트 (20 μ m)가 더 많은 변형 에너지를 저장하고 이로 인해 유효 수명(UL)이 짧아짐을 발견하였으며, 두꺼운 조인트 (60 μ m)는 크리프 에너지가 감소하고 UL이 길어지는 반면 40- μ m 조인트는 크리프와 피로 메커니즘 간의 균형을 가장 잘 보여주었다 [16,17]. Chen 등은 ANNs와 FEA를 결합하여 웨이퍼 레벨 칩에서 솔더 조인트의 피로 저항에 미치는 구조적 매개변수의 영향을 평가하였다 [18]. Yuan 및 Fan은 실험적인 열 사이클링을 인공지능 지원 프레임워크와 통합하여 웨이퍼 레벨 칩 스케일 패키징(Wafer Level Chip Scale Packaging, WLCSPP) 구조의 솔더 조인트 피로를 예측하였다. 실험 데이터는 피로 수명 값과 연관된 평균 플라스틱 변형률을 ANN 및 Recurrent Neural Network (RNN) 모델 훈련에 사용하기 위한 유한 요소 모델의 유효성을 검증하였다 [19]. Ruiz-Jacinto 등은 스택 머신 러닝 접근법(SMLA)을 유한요소해석(FEA)과 결합하여 SAC305 솔더의 저주기 피로(LCF) 수명을 정확하게 추정하는 방법을 소개하였다 [20]. H'ohne 등은 열화 조건 하에서 동일온도 조건의 진동 상태에서 솔더 조인트의 탄성변형률을 예측하기 위해 유한요소해석(FEA)과 신경망을 사용하였다. 그들은 각 솔더 조인트 내에서 가장 스트레스가 높은 20% 요소를 동적으로 선택하고, 탄성 변형률을 추출하여 부피 평균화하여 특정 조건 하에서의 각 솔더 조인트의 변형률을 나타내는 단일 값을 얻었다 [21]. Qasaimeh 등은 전통적인 수명 테스트의 한계를 극복하기 위해 물리학 기반 데이터 주도 방법론을 제시하여 솔더 조인트 수명을 예측하였다. 이 연구는 노화 조건과 솔더 재료와 같은 요인들이 조인트 수명에 미치는 영향을 탐색하였으며, 선형 회귀, 의사결정나무 및 ANN 등 머신 러닝 모델들을 사용하였고, ANN이 가장 높은 예측 정확도($R^2 = 92\%$)를 보였다 [22]. Albrecht 등. 타당성 연구를 수행하여 합성 및 확장된 데이터를 사용해 진동 하중과 온도변환률: 조건과 재료 특성의 영향을 연구하였다. 연구는 통상적으로 사용되는 3D 모델링을 생성하고, 모델이 추출한 데이터는 노출된 진동, 온도와 온도변환률의 효과에 대한 [23]. Reza 등은 공형 워터 테스트 하에서 볼 모양의 솔더 조인트의 유용 수명을 신속하고 정확하게 예측하기 위한 신경망 보조 접근법을 제안하였다. 이 모델은 BGA 칩 위치, PCB 두께, 솔더 합금 구성 및 솔더 공 볼륨과 같은 주요 요소를 고려한다. 또한 이 접근법은 평균 플라스틱 변형률을 활용하여 신뢰성 예측을 향상시켜 안전한 전자 시스템 설계에 적합한 후보로 자리매김하였다.[24].

전반적으로 FEA와 AI를 사용한 BGA 수명 예측을 위한 최신 방법들이 상당한 발전을 이룩하였으며 더 정확한 예측이 가능해졌다. 그러나 이러한 방법들은 특정 지역에서의 플라스틱 변형률을 평균화하는 데 의존하여 솔더 조인트 전체에 걸친 중요한 응력 패턴을 간과할 수 있으며 이로 인해 정보가 누락될 위험이 있다. 이러한 한계는 특히 SMD LED에서 더욱 심각하며, 여기서 변동 요소들이 상당히 크고 복잡하여 [25]에서 제시된 정확도의 제한이 보여진다. 이에 따라 더 고급화되고 자동화된 후처리 방법을 통해 실패 기준을 더 정확하게 정의할 필요성이 증가하고 있다. 세라믹 LED 패키지, 특히 자동차 산업에서는 최적의 솔더 패드 설계를 둘러싼 논쟁이 진행 중이다. 전통적인 수명 모델링 방법은 크리프 응력 값의 수작업 후처리와 수명 데이터와의 상관관계 분석을 포함한다. 저자들이 최근에 발표한 논문 [25]에서는 다양한 SMD 장치 설계, 특히 두 개의 패드와 세 개의 패드를 가진 세라믹 LED의 장기 성능 예측을 위해 FEA를 사용하여 그 신뢰성을 평가하였다. 그러나 이 논문에서는 수명이 “인간 지식”에 기반한 특징과 상관관계를 맺는 방식으로 평가되었다. 예를 들어 특정 위치의 평균 크리프 변형률을 포함한다. 현재까지 어떤 연구도 신경망을 사용하여 2D FEA 크리프 변형률 데이터를 자동으로 특징을 추출해 LED 수명을 예측한 사례는 없다. 이 접근 방식은 네트워크가 2D FEA 격자 맵에서 패턴을 인식하도록 함으로써 수작업 후처리를 대체하여 예측 정확도와 효율성을 향상시킨다. 연구의 목표는 CNN과 FEA의 강점을 결합하여 더 정확하고 신뢰성 있는 수명 예측을 제공함으로써 LED 패키지의 설계 및 내구성을 개선하는 일반적인 수명 모델을 개발하는 것이다.

유한요소해석(Finite Element Analysis, FEA)은 솔더 조인트의 신뢰성과 수명을 예측하는 데 일반적으로 사용되는 도구이며 고출력 LED 패키지에도 활용됩니다. N/A로 표시된 실패까지의 주기를 추정하기 위한 다양한 접근법이 존재하며, 이들 중에는

Coffin-Manson approach is widely used. This method relies on simulating plastic strain as primary indicators of fatigue damage, providing a framework for lifetime predictions.

통상적인 수명 모델링 접근법은 재료의 비선형 거동을 설명하는 구성모델과 함께 사용된다. 일반적으로 네이튼(Norton), 아난드(Anand), 가로팔로(Garofalo) 모델 등이 활용되며, 각각 플라스틱 및 크리프 거동의 다양한 측면을 포착하도록 설계되어 있다. 본 연구에서는 SnAgCu(Su) 솔더의 정상 상태 크리프 거동을 표현하기 위해 가로팔로 모델을 선택하였으며, 특히 이차 크리프에 초점을 맞추고 있다. 다음 식 (1)은 가로팔로 법칙 [26]을 수학적으로 표현한다.

$$\dot{\epsilon} = A[\sinh(\alpha\sigma)]^n e^{(-Q/RT)} \tag{1}$$

ε̇는 시간에 따른 크리프 변형률을 나타냅니다. 가로팔로 모델은 네 가지 매개변수를 포함하며, A는 재료 상수이고, α는 하이퍼볼릭 사인 법칙에서의 응력 곱수이며, n은 응력 지수이고, Q는 활성화 에너지를 나타냅니다. R은 보편 기체 상수이고, T는 절대 온도를 나타내며, σ는 참조 동등응력을 나타냅니다. 활성화 에너지 (Q)는 가로팔로 모델의 중요한 특징입니다. 본 연구에서는 FEA와 가로팔로 모델을 결합하여 SMD 세라믹 LED 패키지의 신뢰성을 평가합니다. SAC 솔더 조인트의 크리프 거동을 모델링함으로써 다양한 SMD 설계의 수명을 더욱 정확하게 예측하는 것을 목표로 합니다.

신경망은 뇌의 수학적 추상화로, 원시 데이터를 입력받는 입력층, 복잡한 계산과 패턴 추출을 수행하는 은닉층, 그리고 결과를 출력하는 출력층으로 구성됩니다. 신경 간 연결에는 가중치가 있으며 이를 통해 네트워크는 데이터로부터 학습하고 예측을 내릴 수 있습니다. 즉, 가중치는 입력 데이터에 기반하여 올바른 출력이 계산될 수 있도록 조정됩니다. 입력과 출력 사이의 관계는 수학적으로 [27]로 표현됩니다.

$$Y = f(W \cdot X + b) \tag{2}$$

여기서 Y는 출력 벡터이며, X는 입력 벡터입니다. W는 가중치를 포함하는 행렬이고, b는 바이어스이며 f는 활성화 함수입니다. 활성화 함수는 비선형성을 도입하여 네트워크가 복잡한 패턴을 학습할 수 있도록 합니다.

컨볼루션 신경망(CNNs)은 이미지와 같은 구조화된 그리드 데이터 처리에 적합하다. CNN의 핵심 구성 요소는 컨볼루션 레이어로, 이 레이어는 입력 이미지에 필터(커널)를 적용한다. 각 필터는 이미지를 움직이며 엘리먼트별 곱셈을 수행하고 결과를 더하여 특징 맵(feature map)을 생성한다. 이러한 필터들은 입력 데이터 내에서 가장자리, 텍스처 및 다른 관련 패턴과 같은 특정 특징들을 감지하도록 설계된다. 이러한 필터를 적용함으로써 네트워크는 이미지 내의 중요한 세부 사항과 공간 계층 구조를 포착할 수 있다. 컨볼루션 연산 후, 특징 맵은 Rectified Linear Unit(ReLU) 활성화 함수를 통과하여 비선형성을 도입하고 복잡한 패턴을 캡처한다.

컨볼루션 및 활성화 단계를 거친 후, CNN은 일반적으로 풀링 레이어를 포함시켜 특징 맵을 추가로 처리한다. 풀링 레이어는 종종 최대 풀링(max pooling)을 사용하여 특징 맵의 공간 차원을 감소시키며, 각 영역에서 가장 큰 값을 선택함으로써 중요한 특징들을 유지하면서 데이터 양과 계산 부담을 줄인다. 풀링 레이어를 거친 후 특징 맵은 일차원 벡터로 평평화(flattened)되어 완전 연결 레이어(fully connected layers)에 입력될 수 있다. 완전 연결 레이어는 밀집 신경망(dense neural networks)에서 사용되는 것과 마찬가지로 고급 추론 및 의사결정을 담당한다 [28].

회귀의 맥락에서 회귀 모델의 최종 완전 연결 레이어는 일반적으로 하나의 뉴런(단일 출력인 경우) 또는 여러 개의 뉴런(다중 출력인 경우)을 가지고 있으며, 예측되는 연속 값을 나타낸다. 이 최종 레이어의 출력은 네트워크가 주어진 입력에 대한 예측으로서 연속 값들을 생성하며, 이는 이산 클래스가 아닌 연속적인 값을 표현한다.

2.4. 최적화 알고리즘과 손실 함수

최적화 알고리즘과 손실 함수는 신경망 훈련의 중요한 구성 요소입니다. Adam (Adaptive Moment Estimation)은 AdaGrad와 RMSProp의 강점을 결합한 방식으로, 신경망 훈련에서 가장 일반적으로 사용되는 최적화 알고리즘입니다. 이 알고리즘은 그래디언트의 첫 번째 모멘트(평균)와 두 번째 모멘트(편향된 분산)에 대한 추정치를 기반으로 학습률을 동적으로 조절합니다. 이를 통해 상대적으로 안정적인 학습률을 유지하면서 그래디언트의 스케일에 적응할 수 있습니다 [29]. 이렇게 하여 Adam은 각 매개변수별로 적응형 학습률을 계산하여 깊은 신경망 훈련에서 매우 효과적입니다. 훈련 중에는 예측 출력이 회귀용으로 적합한 손실 함수, 예를 들어 평균 제곱 오차 (Mean Squared Error, MSE)와 같은 연속적인 목표 값과 비교됩니다. 손실 함수는 예측값과 실제값 사이의 오류를 계산하며, 역전파는 이 오류를 기반으로 그래디언트를 계산하여 네트워크 전체에서 가중치 업데이트를 수행하여 손실을 최소화하고 다양한 반복을 통해 예측 정확도를 향상시킵니다 [30].

데이터셋의 크기가 제한적이라서 신경망을 훈련시키기 위해 데이터 세트를 별도의 훈련용과 테스트용으로 분리하는 것은 실용적이지 않습니다. 대신, 사용 가능한 데이터의 활용을 극대화하기 위해 Leave One Out Cross-Validation (LOOCV)을 사용합니다. LOOCV에서는 각 데이터 포인트가 한 번씩 테스트 세트(단일 점)로 사용되며, 나머지 데이터는 훈련 세트로 사용됩니다. 이 과정은 반복되어 각 데이터 포인트가 정확히 한 번씩 테스트 세트로 사용됩니다. 이러한 방법은 과적합을 피하고 일반화를 더 잘 수행하며,

0부터 1까지의 범위를 가지며, 더 높은 값은 모델 성능이 좋음을 나타냅니다. 1점수는 예측치가 실제값과 완벽하게 일치함을 의미하며, 0점은 모델이 평균을 예측하는 것보다 나아지지 않다는 것을 나타냅니다 [34].

신경망의 내부 작동 원리를 이해하는 것은 그 결정을 해석하고 설계를 개선하는 데 필수적이다. 활성화 맵과 그래디언트 가중 클래스 활성화 맵(Grad-CAM)과 같은 기법은 신경망의 내부 구조를 시각화하고 분석하는 데 중요하다. 활성화 맵, 또는 특징 맵은 CNN에서 각 컨볼루션 필터가 입력 이미지에 적용될 때 생성되는 출력이다. 이 맵들은 필터가 이미지의 특정 영역에서 특정 특징을 감지한 부분을 강조한다 [35]. 또 다른 방법으로는 원래 분류 작업용으로 사용되었던 Grad-CAM이 회귀 작업에도 적용할 수 있어 예측 값에 영향을 미치는 중요한 영역을 시각화하는 데 활용될 수 있다. 회귀에서 이 기법은 마지막 컨볼루션 계층의 특징 맵에 대한 예측 값을 변경하는 그래디언트를 계산한다. 이러한 그래디언트는 특징 맵의 변화가 예측 값에 미치는 영향을 나타낸다. 각 특징 맵에 대한 중요한 가중치는 이 그래디언트들의 평균으로 얻어진다. 그런 다음 이러한 가중치를 사용하여 특징 맵들의 가중 합계를 생성하여 입력 이미지에서 회귀 출력을 결정하는 데 가장 중요한 영역을 강조하는 핫맵을 만든다. 이것은 모델의 예측에 크게 기여하는 입력 부분들을 해석하는 데 도움을 준다 [36].

이 연구는 다양한 솔더 페이스트를 포함하는 광범위한 실험 데이터셋을 기반으로 한다. 이 중 무도금(Lead-free) 변종 다섯 가지가 있으며, 순수 SAC(Sn , Ag, Cu) 합금에서 Sb, Bi, Ni 또는 In과 같은 첨가물을 추가한 것까지 포함한다. 자세한 조성은 [37, 38]를 참조하면 된다. 이 연구에서는 creep 데이터가 문헌에 있는 Garofalo 모델을 위해 SAC305와 SAC105만 시뮬레이션에 선택되었다. 다른 솔더 재료의 실험 creep 데이터 수집은 현재 진행 중이며, 데이터가 도달할 때까지 미래의 시뮬레이션에서 활용될 예정이다.

Fig. 1 shows distinct ceramic LED types with details. The LEDs were soldered to Al-IMS PCB boards. Seven Ceramic Packages were included, each characterized by their unique structures, such as a Flip Chip with solder pads (FC-SP), a Flip Chip with gold bumps (FC-GB), and Vertical Thin Film (VTF). Submount technology further divides the LEDs, where most employ a thick film Aluminum Nitride (AlN) Submount with a substantial 50 μm Copper (Cu) thickness, while others utilize a thinner copper height of solely 5 μm . Footprint also comes into play, varying across symmetrical two-pad, “in-line” three-pad, and “distributed” three-pad configurations, with the size ratio between electrical and thermal pads differing among LED packages.

LEDs were accelerated aged by thermal shock cycling, from -40°C to 125°C with 30 min dwell time through 1500 cycles. This process was monitored using Transient Thermal Analysis (TTA) and Scanning Acoustic Microscopy (SAM) measurements, which












Name in this paper	FC-SP2	FC-SP3	FC-SP4	FC-GB1	FC-GB2	FC-GB3	VTF2
Image							
Cross-Section							
Submount	thick film AlN ceramic	thick film AlN ceramic	thick film AlN ceramic	thick film AlN ceramic	thin film AlN ceramic	thin film AlN ceramic	thick film AlN ceramic
Ceramic [mm ²]	1.6 x 1.6	2.5 x 2.0	1.61 x 1.88	2.3 x 1.9	1.8 x 1.45	1.8 x 1.45	1.9 x 1.5
Thickness [mm ²]	0.76	0.81	0.78	0.62	0.73	0.73	0.69
Pad count	2	3	3	3	3	2	3
Elec. Pads [mm ²]	1.5 x 0.6	0.9 x 0.7	0.59 x 0.57	0.9 x 0.7	0.49 x 0.47	1.6 x 0.47	0.87 x 0.54
Therm. Pad [mm ²]	Non	0.9 x 1.7	0.84 x 1.41	0.9 x 1.65	0.815 x 1.23	Non	0.6 x 1.34
Σ Pad-Size [mm ²]	1.80	2.79	1.86	2.75	1.45	1.49	1.77
Pad-Gap [mm]	0.30	0.45	0.25	0.25	0.30	0.30	0.25
Pad-Ratio	1: 1	1: 2.43	1: 3.52	1: 2.36	1: 4.44	1: 1	1: 1.67
Pad-Design (scaled)							
X-ray (not scaled)							

Fig. 1. Summary of Relevant Parameter of the LEDs [28,29].

열화와 균열 진행을 추적할 수 있다. 이 연구는 열화에서 완전한 전기적 실패에 이르는 다양한 고장 모드를 식별하였다. SAM과 TTA 데이터 간의 명확한 상관관계가 관찰되었다. 수명 데이터는 열 저항이 20% 증가할 때까지의 기준을 사용하여 TTA를 통해 평가된다. 또한, 더 두터운 구리 메탈라이제이션으로 열기계적 불일치를 보완하지 못한 얇은 구리 메탈라이제이션을 가진 LED 패키지들이 낮은 주기에서 고장났다는 점이 관찰되었다. 주요 도전 과제 중 하나는 신뢰성 있는 수명 모델 개발에 필요한 다양한 LED 설계의 데이터 부족이다. 이 문제를 극복하기 위해 연구 데이터는 Kaggle(<https://www.kaggle.com/datasets/andreaszippelius/hellastudy-of-leds2>)에서 공개되어 신경망과 FEA 기반 모델 구축에 활용될 수 있다.


본 연구에서는 Ansys를 사용하여 LED 어셈블리의 단순화된 3D CAD 모델에 대한 열역학적 시뮬레이션을 수행하며, 이는 세라믹 기판 위의 컴포넌트로부터 발생하는 응력 효과를 제외한 것으로 선행 연구에서 이러한 응력이 미미하다고 언급되어 있기 때문입니다 [10]. 모델 단순화에 따른 이 점은 Fig. 2에서 보여집니다.

모델은 알루미늄 핵심을 가진 PCB, 절연체, 그리고 LED가 SAC 솔더를 사용하여 장착된 구리 층을 포함합니다. 알루미늄, 구리 및 SAC 솔더의 재료 특성은 기존 문헌 [30-32]에서 참조되었습니다. Aluminum Nitride (AlN)와 절연체의 특성은 공급업체로부터 제공받았습니다. 본 연구에서는 모든 재료가 제외하고 솔더를 제외한 경우 순수한 탄성재료 간주되며, 이에 대한 세부 사항은 표 1과 표 2에서 제공됩니다. 솔더의 비선형 재료 특성을 위해 Garofalo Creep 모델이 사용되었습니다.

The study uses a symmetrical model, applying a half-model approach to cut computational resources, as shown in Fig. 2. This setup features a plane of symmetry, marked by a dashed line, and incorporates a weak spring to avoid rigid body motion. Simulations start at the solder's melting point of 217 °C, assuming a stress-free state, and cool down to room temperature (22 °C), where they stabilize for three hours to dissipate stress. The model undergoes five thermal cycles from -40 °C to 125 °C, each with a 30-minute dwell time. Mesh size optimization determined an ideal element size of 15 µm for solder and copper pads and 100 µm for other layers, confirmed through mesh convergence studies [25].

그림 3에서 보듯이 FCGB1은 비대칭적인 응력 분포를 가진 세 개의 패드가 있는 LED로, 이는 각각 15 µm인 총 다섯 개의 다른 계층으로 나뉘어진 75 µm의 솔더 계층을 가지고 있습니다. 이전 논문 [25]에서 설명한 바와 같이, 솔더 접합부에서 크리프 변형률을 정밀하게 평가하기 위해 더 높은 CTE 불일치를 보이는 세라믹 층의 상단 15 µm 계층만 고려합니다. 이 15 µm 계층의 각 노드에서 크리프 변형률이 평가되며, 이러한 3D 데이터는 노드 번호, X, Y, Z 좌표 및 각 위치의 크리프 변형률 값이 포함된 Comma Separated Values (CSV) 파일로 내보내집니다. 추가 데이터 처리 방법은 방법론 섹션에서 논의됩니다.

이 연구의 기초가 되는 이전 작업은 두 개의 독립된 논문 [25, 42]에서 상세하게 설명되어 있다. 이러한 논문들은 고효율 LED 패키지의 솔더 조인트 신뢰성에 초점을 맞추고 다양한 LED 패드 설계를 위한 수명 예측 모델을 개선하기 위해 유한요소해석(Finite Element Analysis, FEA)을 사용한다. 그런 다음 Coffin-Manson 접합법과 완전연결 신경망(Completely Connected Neural Networks)을 이용하여 수명 예측을 수행하는데, 이는 크게 다르다.



Layer description from top to bottom:

LED package:

LED die (not included)
Die attach (not included)
Copper (not included)
AlN ceramic
Copper

IMS-PCB:

- Copper
- Dielectric
- Aluminium

Fig. 2. Detailed CAD Model [25].

Table 1
Material Properties [39].

Material	Youngs Modulus (GPa)	Poisson Ratio	CTE (ppm/°C)

Table 2
Garofalo Model Parameter [39–41].




Fig. 3. Creep strain in a 75 μm FC-GB1 solder pad across five 15 μm layers from top (high strain) to bottom (low strain).

이전 연구에서 사용된 방법론은 동일한 FEA 모델 설정을 포함한다. 그러나 두 가지 다른 FEA 후처리 방법이 비교된다: 층 평균화와 임계 경로 평균화이다. 층 평균화는 솔더 패드의 다양한 깊이에서 변형률의 평균 값을 계산하며, 임계 경로 평균화는 실험적으로 결정된 균열 확장에 가장 취약한 경로를 집중적으로 고려한다. 결과는 15 $\times$ m 층 평균화가 SAC305와 SAC105의 실험 데이터와 좋은 상관관계를 보여 R² 점수 각각 0.79와 0.92를 기록했다고 나타났다. 그러나 균열 길이의 30%에서 임계 경로 평균화가 실험 데이터와 더 잘 일치하여 R² 값을 달성한다.

점수로 각각 SAC305에 대해 0.85, SAC105에 대해 0.97을 기록한다. 전체적인 정확도에도 불구하고 얇은 필름 세라믹 패키지(FC-GB2 및 FC-GB3)는 구조적 특성의 차이로 인해 예측 오류가 크게 나타난다 [25].

두 번째 논문은 이 분석을 확장하여 SAC387 + SbBiNi 및 SAC107 + BiIn 두 가지 더 많은 솔더를 도입하고, creep 변형률과 수명 데이터 간의 상관관계를 구하기 위해 Fully Connected Neural Network (FCNN)를 통합하며 Coffin Manson 접근법을 제거한다. FCNN은 범주형 변수에 대해 훈련 가능한 임베딩을 사용하여 예측 정확도를 향상시킨다. 이 아키텍처는 밀집층 네트워크를 사용한다.

FCNN 모델은 전통적인 Coffin-Manson 방정식에 비해 SAC305와 SAC105의 수명 예측을 크게 향상시켰으며, 중요한 경로 평균화를 통해 전체 R² 점수 0.87을 달성했다. SAC387 + SbBiNi 및 SAC107 + BiIn에 대한 더 큰 예측 오차는 실험 데이터의 높은 불확실성을 이유로 Garofalo 모델 매개변수를 더욱 정교하게 조정할 필요가 있음을 시사하여 이 논문에서는 이러한 솔더들을 무시한다. 임베딩 사용으로 인해 모델이 다양한 LED와 솔더 유형의 특징을 효과적으로 포착할 수 있었으며 일반화 및 예측 정확도를 향상시키는데 기여했다. 그러나 다른 솔더들의 Garofalo creep 모델 매개변수를 추출하기 위한 추가 실험이 진행 중으로, 이를 통해 미래 논문에서 다룰 데이터 범위가 확장될 것이다.

통합 연구는 FEA와 FCNN을 통합함으로써 솔더 조인트 신뢰성 예측에 대한 견고한 프레임워크를 제공한다는 결론을 내렸다. 중요 경로 방법은 두꺼운 필름 LED에 대해 더 나은 예측 정확도를 보여주며, 레이어 평균화도 강력한 결과를 나타냈다. 두 연구 모두 다양한 LED 설계를 수용하기 위한 모델의 추가 세분화가 필요하다는 점과 재료 특성의 세분화 및 CNN과 트랜스포머와 같은 고급 신경망을 탐색함으로써 정확도 향상을 추구해야 한다고 강조하고 있다. 이 논문에서는 이러한 접근 방식이 사용되었다.

방정식은 수동 후처리를 위해 FEA 데이터를 사용하며, 여기서 응력변형률은 실패 기준을 수동으로 정의한 구간에서 평균화됩니다. 이 평균화는 중요한 정보 손실과 팔드 식스터링 층 내에서 크리프 변형률의 이산적 패턴을 잃게 하여 데이터의 전체 복잡성을 포착하는 데 효과적이지 않습니다. CNNs를 사용함으로써 우리는 특징 추출을 자동화하여 수동 방법이 간과하는 세부적인 공간 패턴을 보존합니다. 이는 분석의 효율성과 정확성을 향상시키며, 전체 데이터 깊이를 활용하여 팔드 조인트 수명 예측의 신뢰성을 개선합니다.

FEA 시뮬레이션에서 수집된 모든 세라믹 LED의 데이터를 처리한 후, 전체 3D FEA 데이터를 직접 신경망에 통합하는 것은 계산적으로 부담스럽고 많은 시간이 소요됩니다. 이를 해결하기 위해 평균화 방법을 사용하여 프로세스를 단순화하고 데이터 차원성을 3D에서 2D로 줄입니다. 데이터를 평균화할 때 X, Y 또는 Z 축 방향으로 다양한 접근법을 취할 수 있습니다. Z축 방향의 평균화는 솔더 패드의 두께를 나타내며, 이는 세라믹과 솔더 층 사이의 불일치가 가장 큰 상단 솔더 층에서 발생하기 때문에 선택되었습니다. 이 영역은 더 많은 변형을 경험하므로 Z축 평균화는 솔더 조인트 파열에 영향을 미치는 중요한 기계적 특성을 포착하는 데 필수적입니다. X 및 Y 축 방향의 평균화는 데이터 포인트 수를 줄이고 정보 손실을 증가시킵니다. 이 사전 처리 단계는 모델이 CNN 처리를 위해 관리 가능한 형태로 유지하면서 중요한 특징을 보존하도록 합니다.

도표 4(a)와 (b)에서 Z축은 솔더 패드의 두께 방향으로 취해집니다. 이는 더 포괄적인 집계를 가능하게 하기 때문입니다. 솔더 패드의 두께 방향을 따라 평균화하면 일부 정보가 손실되지만, 데이터 전처리 과정에서 이를 줄이고 처리 가능한 크기로 축소할 때 항상 발생하는 현상입니다. 다음 단계는 신경망에 입력될 준비를 하는 것입니다. 모든 솔더 패드의 크기가 다르므로, 일관된 입력 형태를 제공하기 위해 그리드 맵을 정의하고 보간을 수행해야 합니다. 통일된 그리드 크기를 설정하는 것은 솔더 패드를 정확하게 분석하는 데 필수적입니다. 이 접근법은 신경망의 해상도와 입력이 모든 솔더 패드에서 일관되게 유지되도록 하며, CNN 기반 모델에서도 이러한 통일된 입력 데이터는 필수적입니다.

그리드 크기는 분석에서 가장 많은 노드 수를 가진 FC-SP3에 기반하여 결정됩니다. 그런 다음 이 그리드의 x-y 축에 동일한 간격으로 점을 설정합니다. 일정한 그리드 크기는 모든 솔더 패드가 같은 해상도로 분석되도록 보장합니다. 이러한 균일성이 없으면 다른 솔더 패드는 서로 다른 해상도를 가질 수 있으며, 이는 잠재적인 편향을 초래할 수 있습니다. 예를 들어, 더 작은 그리드 크기(높은 해상도)를 가진 솔더 패드는 더 정확한 결과를 제공할 수 있지만, 더 큰 그리드 크기(낮은 해상도)를 가진 솔더 패드는 덜 정확한 결과를 제공할 수 있습니다. 이러한 불일치는 편향을 초래하고 잘못된 결론에 이르게 할 수 있습니다. 따라서 모든 솔더 패드에서 균일한 그리드 크기를 유지하는 것은 공정하고 정확한 비교를 위한 필수 조건입니다.

일정한 그리드 크기가 정의되면 이러한 그리드 점들이 보간을 위한 샘플링 위치로 사용됩니다. 선택 보간은 이전 단계에서 생성된 2D 유한요소해석(Finite Element Analysis, FEA) 데이터를 Z축 방향으로 평균화한 후에 각 점의 creep 변 d를 추정하기 위해 수행됩니다. 그림 5(a)는 평균화 이후 산점도를 보여주며, 5(b)는 FC-SP3 LED에 대한 보간 과정과 샘플링 포인트의 분포를 나타냅니다. 그러나 그리드는 X와 Y 위치별 creep 변 d를 포함하는 FEA 데이터의 전체 구조를 유지합니다.

이 예처리 단계는 이 두 용제(SAC305와 SAC105)에 대한 7개의 LED 모듈에 적용됩니다. 이러한 14개 그리드가 CNN 입력 데이터로 사용되어 수명 데이터와 상관분석됩니다. 데이터가 정의된 후 다음 단계는 CNN 아키텍처를 정의하여 이를 평가하기 위한 작업입니다.




Fig. 4. Solder Pad (a) FC-SP2 (Electrical Pad) (b) FC-SP3 (Top –Thermal and Bottom – Electrical Pad) (across Z axis).




Fig. 5. FC-SP3 (Top – Thermal and Bottom – Electrical Pad) (a) After averaging (b) Grid Interpolation.

표 3에서는 복잡도가 증가하는 아홉 가지 서로 다른 CNN 구조를 ReLU 활성화 함수, 맥스 풀링(Max pooling), 그리고 Adam 옵티마이저를 사용하여 설계한 내용을 정리하였다. 이 모델들의 합성곱(Convolutional) 레이어는 가장 간단한 모델에서 1개 필터부터 가장 복잡한 모델에서는 64개 필터까지 다양하다. 밀도(Dense) 레이어는 Model 1에서 2개의 뉴런으로 시작하여 점진적으로 증가하여, Model 9에서는 128개의 뉴런을 가진다. 학습 가능한 매개변수는 필터 수가 모델마다 증가하는 합성곱 레이어와 뉴런 수도 증가하는 밀도 레이어에서 모두 나타난다. 각 합성곱 레이어에서는 (3×3) 크기의 필터를 스트라이드(stride) 1과 "same" 패딩을 사용하여 공간 차원을 유지하도록 적용되며, 이는 맥스 풀링(Max pooling)이 적용되기 전까지 유지된다. 맥스 풀링은 (2×2) 필터와 스트라이드 2를 사용하며, 이것은 특징 맵의 차원성을 줄이는 동시에 가장 중요한 정보를 보존하는 표준적인 접근법이다.

이러한 합성곱 레이어의 필터는 훈련 과정에서 학습된다. 각 필터는 입력 데이터에 따라 가중치가 조정되어 모델이 데이터에서 가장자리, 패턴 및 기타 공간 구조와 같은 다양한 특징을 감지할 수 있도록 한다. 이러한 레이어들과 밀도 레이어들이 함께 추출된 특징을 목표 값(회귀 출력)으로 변환하는 최종 매핑을 수행한다. 한편, Rescaling, 맥스 풀링(Max pooling), 및 Flatten 레이어는 학습 가능한 매개변수가 없지만 후속 레이어를 위한 데이터 준비를 위해 고정된 변환을 수행한다.

모델 9은 일반적으로 다른 모델들에 비해 유망한 결과를 보여주며, 이 결과는 다음 섹션에서 자세히 설명될 것이다; 그림 6에 나타난 아키텍처는 회색조 이미지($300 \times 300 \times 1$)를 위한 입력 레이어로 구성되어 있으며 여기서 300×300 은 이미지의 크기를, 1은 회색조를 의미하며 RGB인 경우 일반적으로 3을 사용한다. 이에 이어서 픽셀 값을 정규화하기 위한 리스케일링 레이어가 추가되었다. 모델은 두 개의 합성곱 레이어로 구성되어 있으며, 첫 번째는 32개 필터를, 두 번째는 64개 필터를 사용하며 ReLU 활성화 함수를 적용하였다. 각 합성곱 레이어 이후 맥스 풀링(Max pooling) 레이어가 사용되어 공간 차원을 줄인다. 이러한 레이어들의 출력은 1차원 벡터로 평평하게 변환되었으며, 이는 128개의 뉴런과 ReLU 활성화 함수를 가진 완전 연결 밀도(Dense) 레이어에 입력된다. 최종 레이어 또한 단일 유닛을 가지며 선형 활성화 함수를 사용한 밀도(Dense) 레이어로 구성되어 회귀 작업에 적합하도록 설계되었다. 모델은 $3e-4$ 의 학습률을 가진 Adam 옵티마이저와 평균 제곱 오차(Mean Squared Error, MSE)를 손실 함수로 사용하여 컴파일되었다.

검증을 위해 Leave-One-Out Cross-Validation (LOOCV)이 사용되었다. 이 방법은 각 샘플을 순차적으로 검증 세트로 사용하면서 나머지 샘플들을 훈련 세트로 활용하는 방식이다. LOOCV는 특히 소규모 데이터셋에서 유용하며, 모든 샘플이 훈련과 검증에 이용될 수 있도록 한다. 각 LOOCV 폴드에서는 모델을 200 에포크 동안 훈련시키고, 그 성능은

Table 3
Different CNN architecture.

Model	Convolutional Layers	Activation Function	Pooling Layers	Dense Layers	Optimizer
-------	----------------------	---------------------	----------------	--------------	-----------




Fig. 6. CNN Final architecture (model 9) – FEA data grid as input and Lifetime data as output.

검증 세트에서 평가되었으며 각 반복마다 손실이 기록되었습니다. 이 과정은 데이터셋의 각 샘플에 대해 반복되었습니다. 각 폴드의 검증 손실을 평균화하여 모델 성능의 전체적인 측도를 제공했습니다. 이 아키텍처는 분류에서 동일한 LOOCV 구현과 유사하게 사용되었지만 이번에는 회귀 최적화를 위해 조정되었습니다 [43-45]. 또한 예측 값의 정규화가 목표값을 이미지와 같은 전처리된 스케일로 비교할 수 있도록 하는 중요한 단계였습니다. 이를 통해 신경망의 더 빠른 수렴과 안정적인 학습이 가능했습니다. 이 과정은 최소-최대 정규화를 통해 목표값을 0에서 1 사이의 범위로 조정하여 수행되었습니다. 이러한 엄격한 검증 과정의 결과는 모델이 미지의 데이터에 잘 일반화할 수 있음을 보여주었으며 선택된 아키텍처, 전처리 단계 및 검증 전략의 효과성을 나타냈습니다. 이러한 요소들을 결합함으로써 강건한 평가를 수행하여 발견 결과가 신뢰적이고 재현 가능하도록 했습니다. 이 상세한 방법론은 전처리 과정, 모델 아키텍처, 최적화, 손실 함수 및 검증 접근법을 명시하여 이 연구에서 사용된 신경망에 대한 종합적인 이해를 제공합니다.

신경망 분석에서 다양한 기법들이 네트워크의 내부 구조를 시각화하고 이해하는 데 활용되었습니다. 활성화 맵은 컨볼루션 계층으로부터 생성되어 네트워크 내의 훈련 가능한 필터가 입력 이미지의 다양한 특징에 어떻게 반응하는지를 관찰할 수 있게 해주어 계층적 특징 추출 과정에 대한 통찰력을 제공합니다. 또한, Grad-CAM 맵은 예측을 만드는 데 가장 중요한 영역이 어느 부분인지 이해하는 데 사용됩니다. 이러한 기법들의 결합은 네트워크의 내부 작동 방식을 이해하는 데 도움을 주며 모델 내에서 특징 추출 및 의사결정 과정에 대한 종합적인 시각을 제공합니다.

이 섹션에서는 CNN을 사용하여 유한요소해석 격자 방법에 대한 심층 평가를 제시하며, 모델 내의 의사결정 과정을 이해하기 위한 다양한 지표들을 활용한다. 이 연구에서 입력 데이터는 두 가지 종류의 솔더(SAC305와 SAC105)와 일곱 가지 다른 LED에 대한 FEA 격자로 구성되어 있으며, 총 14개의 독립적인 입력이 CNN으로 전달되어 수명 값 예측을 수행한다. 동일한 입력 및 출력 데이터 세트를 사용하여 아홉 개의 서로 다른 네트워크 구조가 훈련된다. 첫 번째 네트워크는 R2 점수 0.80을 달성하며, 두 번째부터 일곱 번째 네트워크는 마지막 두 자리 수가 변하는 것 외에는 동일한 R2 점수인 0.93387을 얻는다. 그러나 여덟 번째 구조는 성능 향상을 보이며, R2 점수가 0.9778을 달성한다. 아홉 번째 네트워크는 가장 우수한 성능을 보여 R2 점수가 0.99867을 기록한다. 이 결과 모델이 수명 데이터의 변동성을 거의 완전히 포착할 수 있음을 나타내며, 이는 그림 7b에서 99.867%의 가변성 설명을 보여준다. 또한 그림 7a에 표시된 손실 곡선은 모델이 200 에포크까지 훈련되는 것을 나타낸다.




Fig. 7. Loss curve Actual vs Predicted Lifetime Values using CNN.

모델이 underfitting인지 overfitting인지를 확인하고, 이는 훈련 및 검증 손실이 50 에포크 이후에 정체됨을 명확히 보여주며, 손실이 수렴하거나 발산하지 않았다는 점은 모델의 동작을 체크하는 데 매우 중요하며, 더 높은 값의 에포크로 훈련시키기 위한 중요한 요구사항입니다.

FEA 그리드 데이터를 사용할 때 성능 향상이 관찰됨으로써 모델이 복잡한 특징 표현을 학습하고 데이터 내에 숨겨진 패턴을 효과적으로 포착할 수 있음을 알 수 있습니다. 이 개선된 능력은 이전 관련 연결한 신경망(FCNN) 연구와 비교했을 때 특히 중요하며, 이들 연구는 최대 R2 점수로 0.87 [42] 만 달성했습니다. 모델은 변동의 87%만 설명할 수 있었고, 나머지 13%는 설명하지 못한 반면에 FEA 그리드 데이터를 사용하는 CNN 모델은 수명 예측에서 거의 모든 변이성을 설명합니다. Coffin-Manson 방정식과 같은 전통적인 방법들은 한계가 있습니다. Coffin-Manson 접근법은 단일 FEA 데이터 포인트를 수명 데이터와 상관시키는 경우 귀중한 정보의 손실을 초래하고 덜 정확한 예측을 생성할 수 있습니다. 종합적인 FEA 그리드 데이터를 고려하면 CNN 모델은 크리프 변형 값 전체 그리드를 고려하여 이러한 한계점을 극복하며 더 정확하고 세부적인 예측을 제공합니다.

Fig. 8 illustrates the predicted and actual lifetime values for two solder types, SAC305 and SAC105, across various LEDs. For SAC305, the model demonstrates high accuracy in its predictions. Specifically, FC-GB2 has a slight error of 0.52 %, FC-GB3 shows a minimal error of 0.23 %, FC-SP3 has an error of 1.11 %, and FC-SP4 has an error of 0.30 %. VTF2, however, exhibits a notable error of 1.37 %. FC-SP2 has a small error of 0.24 %, while FC-GB1 shows a minor error of 0.29 %.

SAC105에 대한 모델의 예측도 높은 정확성을 보여줍니다. FC-GB3는 실제 값과 일치하는 예측을 하였으며 오차가 없습니다. FC-GB2는 0.24%의 작은 오차를 보이고, VTF2는 가장 큰 예측 오차인 3.68%를 나타냅니다. FC-SP3은 0.78%의 작은 오차를, FC-SP2는 0.30%의 오차를, FC-GB1은 0.12%의 미세한 오차를, 그리고 FC-SP4는 0.23%의 작은 오차를 보입니다. 전반적으로 모델은 대부분의 LED에 대해 최소한의 오차로 잘 작동하지만, SAC105에서 VTF2에서는 큰 예측 오차가 관찰됩니다. 이러한 오차에도 불구하고, 모델은 SAC305에서도 상대적으로 정확한 예측을 보여주어 두 개의 솔더 유형 모두에 대한 데이터 패턴을 효과적으로 포착하고 있음을 나타냅니다. 전반적으로 CNN 기반 모델은 이전 연구 [25]에서와 비교해 높은 예측 정확성을 보입니다. 특히 얇은 구리 메탈라이제이션을 가진 LED, FC-GB2 및 FC-GB3에 대한 큰 편차가 발생합니다.

모델의 해석 가능성은 CNN과 같은 머신 러닝 모델이 어떻게 예측을 내리는지 이해하는 데 필수적입니다. 특히 자동차 LED에서 솔더 조인트 수명을 예측하는 것과 같은 응용 분야에서는 더욱 그렇습니다. 해석 가능성이 없으면 모델의 의사 결정 과정은 "블랙 박스"로 남게 되어 사용자가 모델이 특정 예측을 내리는 방식이나 이유를 이해할 수 없습니다. 이러한 투명성 부족은 특히 자동차 안전과 같은 중요한 응용 분야에서 신뢰성을 저해할 수 있습니다.

따라서 Grad-CAM과 같은 기법은 모델이 입력 데이터의 특정 영역을 강조하는 방식을 시각화하여 귀중한 통찰력을 제공합니다. Grad-CAM은 모델의 최종 예측에 가장 큰 영향을 미치는 특정 지역을 강조 표시하는 핫맵을 생성합니다. 이러한 도구들은 의사 결정 과정을 투명하게 만들어, 모델이 정확한 뿐만 아니라 인간 전문 지식과도 일치하도록 보장하여 최종적으로 더 잘 설계되고 신뢰성 있는 제품 개발에 기여합니다.

그림 9에서와 같이, Grad-CAM 맵은 모델의 예측에 가장 큰 영향을 미치는 입력 이미지의 특정 지역을 시각화하는 귀중한 도구입니다. 모든 입력에 대해 핫맵은 모델이 주목하는 구체적인 영역을 강조합니다. 그림 9에서 검붉은 색 부분은 최고의 영향력을 나타내며, 파란색 영역도 예측에 미약하지만 역할을 합니다. 이러한 시각화는 모델의 해석 가능성 이해를 돕고, 모델 의사결정 과정에 대한 신뢰성을 높여줍니다. 이 핫맵 분석은 LED 패키지에서 내재된 실패 메커니즘과 중요한 스트레스 또는 응력 영역을 파악하는 데 필요한 중요한 통찰력을 제공하며, 모델 예측에 영향을 미치는 지역을 식별하고 이를 통해 모델이 두 개의 패드나 세 개의 패드를 가진 LED를 구분할 수 있음을 보여줍니다.

汽缸에서 이 방법은 예측 정확도를 향상시키는 데뿐만 아니라 후처리 FEA 데이터에 필요한 시간과 자원을 크게 줄이는 데에도 기여합니다. 고급 신경망 아키텍처를 활용함으로써 제조업체는 솔더 조인트나 다른 인터커넥트의 수명을 신속하고 신뢰성 있게 평가할 수 있으며, 이를 통해 설계 반복 주기를 더 빠르게 하고 보다 신뢰성 있는 전자 시스템을 구현할 수 있습니다. Grad-CAM 열지도와 같은 가시화 기법은 모델의 결정을 더욱 명확하게 해석할 수 있게 하여 예측에 영향을 미치는 중요한 지역에 대한 명확한 통찰력을 제공합니다.

세 가지 카세트 기반의 LED 패키지에서 SAC305 및 SAC105 솔더 합금을 사용한 검증은 CNN 모델의 뛰어난 성능을 보여주었으며, 이는 거의 완벽한 R2 점수 0.99867을 달성함으로써 입증되었습니다. 이를 통해 모델이 FEA 데이터 내에서 복잡한 패턴과 공간적 의존성을 포착하는 능력을 강조하며, Coffin-Manson 방정식 및 완전 연결 신경망(FCNs)과 같은 전통적인 방법들보다 훨씬 우수한 성능을 보였음을 알 수 있습니다. 특히 얇은 구리 메탈라이제이션을 가진 LED 패키지에 대해서는 더욱 그렇습니다.

그러나 연구 결과는 더 적은 컨볼루션 레이어와 필터를 가진 단순한 모델들이 그보다 복잡한 모델들에 비해 성능이 떨어짐을 보여주고 있습니다. 이 성능 차이는 단순한 모델들이 FEA 그리드 데이터 내의 복잡한 특징들을 포착하는 능력이 제한적이라는 점 때문일 가능성이 큼니다. 또한, 작은 데이터셋 크기는 이러한 한계를 더욱 악화시키는데, 단순한 모델들은 정확한 예측을 위해 충분한 특징을 추출하기 어려울 수 있습니다. 반면에 더 큰 모델은 파라미터와 필터의 수가 많아서 제한된 데이터셋에서도 세부적인 다양한 특징들을 학습할 수 있는 능력을 갖추고 있습니다.




Fig. 8. Actual vs Lifetime prediction values.




Fig. 9. Grad- CAM Heatmap for all LEDs.

SAC305 및 SAC105 합금에 대해서만 해당한다. 현재 중요한 문제는 이러한 유망한 모델을 큰 데이터 세트와 더 큰 변동성을 가진 경우에도 얼마나 정확할지 여부이다. 따라서 데이터 세트를 확대하는 것이 중요하다. 이를 위해 한편으로는 연구에서 사용된 다른 솔더에 대한 크리프 측정이 진행되고 있으며, 다른 한편으로는 패키지 유형을 다양화하고 프린티드 회로 보드도 변경하여 5000개 이상의 LED 패키지를 추가 제작하는 작업이 시작되었다. 이 시점에서 공개 데이터의 사용 가능성이 필요하며, 이를 통해 산업계가 다양한 인공지능 기반 수명 모델을 구축할 수 있는 충분한 데이터베이스를 제공받아야 한다.

결론적으로, 유한요소해석(Finite Element Analysis, FEA) 데이터와 컨볼루션 신경망(CNN)의 통합은 LED 패키지의 신뢰성 예측을 획기적으로 개선시킨다. 이 접근법은 빠르고 자동화된 방법으로 고도로 정확한 수명 예측을 제공하여 더욱 신뢰할 만한 전자 시스템 개발에 기여하며, 특히 자동차 산업뿐만 아니라 다양한 분야에서도 실질적인 혜택을 가져다준다. 향후 연구에서는 이 방법론을 다른 전자 패키지와 스트레스 조건으로 확장하는 것을 고려할 수 있으며, 정확도와 일반화를 높이기 위해 추가 데이터 소스를 통합하는 것도 가능하다. 또한 3D FEA 데이터와 3D CNN의 사용은 솔더 패드의 두께에 걸친 복잡한 패턴을 더욱 자세히 포착할 수 있다.

모하드 주바이르 아크htar: 개념화, 방법론, 소프트웨어 개발, 데이터 관리, 원고 작성. 막심ilian 술midt: 시각화, 데이터 관리. 안드레아스 작페琉璃烏斯: 리뷰 및 편집. 고든 엘게르: 리뷰 및 편집, 감독, 연구 자금 확보.

저자들은 다음과 같은 재정적 이해관계 또는 개인 관계를 선언합니다. 이러한 이해관계가 연구 결과에 영향을 미칠 수 있는 경쟁적 요인으로 간주될 수 있습니다: 모하드 주바이어 아크타르는 BMWK 및 BMBF로부터 재정 지원을 받았으며, 베를린 교육부와의 관계를 보고합니다. 이 관계에는 연구 자금 지원이 포함됩니다. 골든 엘저는 바이에른 주 경제, 지역 개발 및 에너지 부처와의 관계를 보고하며, 이 관계에는 연구 자금 지원이 포함됩니다. 다른 저자들이 있다면 그들은 자신들의 재정적 경쟁 이해관계 또는 연구 결과에 영향을 미칠 수 있는 개인적인 관계가 없다고 선언합니다.

이 연구는 바이에른 주 경제, 지역 개발 및 에너지 부처의 MAWIS KI (FKZ DIK-2106-0016//DIK0265/01) 프로젝트를 통해 助助的.

본 연구의 전체 데이터 세트는 "고출력 LED와 솔더 페이스트의 신뢰성"이라는 제목으로 www.kaggle.com에서 오픈 소스로 발표되어 있습니다.

- [1] 장즈 Hong, 왕 쉬싱, 레니 환홍, 자아 시우, 왕 환홍, 패키징패키지 구조의 솔더 조인트에 대한 열-피로 파괴 특성의 시뮬레이션 연구, *Microelectron. Reliab.* 75 (2017) 127-134, <https://doi.org/10.1016/j.microrel.2017.06.033>.
- [2] Liu, J.; He, L.; Chen, H.; Zhao, P.; Su, Y.; Chao, L.; Pan, Q. Sn63Pb37 BGA 솔더 조인트의 열 사이클 부하 하에서 신뢰성 시뮬레이션 및 수명 예측. 2020 China Semiconductor Technology International Conference (CSTIC) 논문집, 상하이, 중국, 2020년 6월 26일-7월 17일; pp. 1-4.
- [3] Depiver 제, Mallik 시우, Amalu 디어, BGA 솔더 조인트의 열 피로 수명: 다양한 합금 구성으로 만든 경우, *Eng. Fail. Anal.* 125 (2021) 105447, <https://doi.org/10.1016/j.engfailanal.2021.105447>.
- [4] Zhang 린, Chee 쉬싱-수, Maheshwari 아난드, Fucnell 알렉산더. Cavity down BGA 패키징 솔더 조인트 신뢰성에 대한 실험 및 유한요소해석(Finite Element Analysis, FEA). 3rd Electronics Packaging Technology Conference (EPTC 2000) (Cat. No. 00EX456) 논문집, 싱가포르, 2000년 12월 7일; pp. 391-397.
- [5] Halouani 아부드, Cherouat 알리, Miladi Chaabane 메리엠, 하다르, 저온주기 열사이클 하에서 낮은 프로파일 쿼드 플랫 패키지의 크리프-피트니스 및 파괴 모델링과 실험, *Proc. Inst. Mech. Eng., Part C: J. Mech. Eng. Sci.* 234 (21) (2020) 4277-4287, <https://doi.org/10.1177/0954406220920680>. [6] 주우, 쯔, 황(Chiou, Y.-C., Jen, Y.-M., Huang, S.-H.), 유한요소해석(Finite Element Analysis, FEA) 기반의 인터메탈리크 컴파운드 성장 효과를 고려한 솔더 조인트 피트니스 산출, *Microelectron. Reliab.* 51 (12) (2011) 2319-2329, <https://doi.org/10.1016/j.microrel.2011.06.025>. [7] 천, 판(Che, F.X., Pang, J.H.), 스넬라지(Sn-Ag-Cu) 솔더 조인트의 열사이클에 따른 피트니스 신뢰성 분석, *IEEE Trans. Device Mater. Reliab.* 13 (2013) 36-49. [8] 시어드(Syed, A.), 누적 크리프 변형률과 에너지 밀도 기반 스넬라지(SnAgCu) 솔더 조인트의 열피트니스 수명 예측 모델, 2004 Proceedings. 54th Electronic Components and Technology Conference (IEEE Cat. No. 04CH37546), 1, 737-746 Vol. 1. [9] 크루즈(Cruz, R.S.) 및 곤다(Gonda, V.), "SAC305와 도핑된 SAC 솔더에 대한 크리프 변형률 에너지 밀도 기반의 솔더 조인트 신뢰성," *MATEC Web of Conferences*, 2021. [10] 샤이기(Shaygi, M.), 리(Li, M.), 랑(Lang, K.-J.), 로우스(Laux, H.) 및 베(B., J.), 원더러(Wunderle), "자동차용 파워 LED 조인트 신뢰성에 영향을 미치는 요소의 수치 및 실험적 연구," 2022년 제23차 마이크로전자 및 마이크로시스템에서 열, 기계 및 다물리학 시뮬레이션 및 실험 국제 컨퍼런스 (EuroSimE), 말타 세인트줄리안, 2022, pp. 1-9, doi: 10.1109/EuroSimE54907.2022.9758848. [11] B. Wunderle 외 등, 포워드 칩온보드 어셈블리의 캡슐화 기술 개발 시기 열-기계적 신뢰성, *Microsyst. Technol.* 15 (9) (2009) 1467-1478. [12] 서바야난(Subbarayan, G.), 리(Li, Y.), 및 마하잔(Mahajan, R.L.) (1996). 확률적 유한요소해석(Finite Element Analysis, FEA)과 인공신경망(artificial neural network) 모델을 이용한 솔더 조인트 신뢰성 시뮬레이션.

<https://doi.org/10.1115/1.2792145>. [13] A. Qasaimeh, S. Lu, P. Borgesen, 리드프리 솔더 조인트의 균열 진화 및 빠른 수명 평가, 2011 IEEE 제61회 전자 부품 및 기술 컨퍼런스 (ECTC), IEEE, 2011, pp. 1283-1290, <https://doi.org/10.1109/ECTC.2011.5898676>. [14] Y. Sung, J. Robert, 솔더 조인트 신뢰성 예측을 위한 머신 러닝 프레임워크, *Solder. Surf. Mt. Technol.* 32 (2019) 82-92. [15] Z. Zhao, Z. Chen 및 S. Liu, "Hybrid FEM-ANN-PSO Method To Optimize The Structural Parameters Of Wafer-Level Chip Scale Package (WLCSP) For High Reliability," 2020 제21회 국제 전자 패키징 기술 컨퍼런스 (ICEPT), 광저우, 중국, 2020, pp. 1-5, doi: 10.1109/ICEPT50128.2020.9202650. [16] V. Samavatian, M. Fotuhi-Firuzabad, M. Samavatian, P. Dehghanian, F. Blaabjerg, 가속화된 전자 회로 솔더 조인트 신뢰성 평가를 위한 상관관계 기반 머신 러닝, *Scient. Rep.* 10 (2020). [17] V. Samavatian, M. Fotuhi-Firuzabad, M. Samavatian, P. Dehghanian, F. Blaabjerg, 피로와 크리프 손상 사이의 다리를 연결하는 반복적인 머신 러닝 보조 프레임워크, *IEEE Trans. Compon., Packag.* [18] Z. Chen, Z. Zhang, F. Dong, S. Liu, L. Liu, 하이브리드 유한요소 모델링: 인공신경망 접근법을 이용한 웨이퍼 레벨 칩 스케일 패키지의 솔더 조인트 피로 수명 예측, *J. Electron. Packag.* 143 (1) (2021) 011001, <https://doi.org/10.1115/1.4047227>. [19] C. Yuan, X. Fan, G. Zhang, AI 지원 시뮬레이션 프레임워크를 이용한 유전 알고리즘 최적화로 인공지능 모델 초기 매개변수를 최적화하여 솔더 조인트 신뢰성 위험 평가, *Materials* 14 (2021) 4835, <https://doi.org/10.3390/ma14174835>. [20] V. Ruiz-Jacinto, K. Gutiérrez-Valverde, A. Aslla-Quispe, J.M. Burga-Falla, A. Alarcón-Sucasaca, Y. Huamán-Romani, 저주기 피로 수명 평가를 위한 FEM-데이터 주도 기계학습 접근법을 이용한 SAC 솔더 합금, *Soldering & Surf. Mount. Technol.* (2023). [21] R. Höhne, O. Albrecht, Y. Qi, K. Meier, K. Bock, FEA를 사용한 전자 신뢰성 분석을 위한 기계학습의 타당성 조사, in: 2023 IEEE 73rd Electronic Components and Technology Conference (ECTC), IEEE, 2023, pp. 1181-1186.

- [22] Qasaimeh, Qais 등. "물리 정보 기반 데이터 주도 방법을 이용한 전자 조립체 패치 점 접합 수명 예측." 2023년 IEEE 열 및 테르모메카니컬 현상 전자 시스템 국제 학회(Itherm). IEEE, 2023. [30] Wei, Q., Cao, B., Yuan, H. 등. Divide and conquer: 기계학습 가속화를 통한 무도성 및 높은 연신율을 갖는 무납금 패치 점 합금 설계. *npj Computational Materials* 9, 201, 2023. [23] O. Albrecht, R.D. H'ohne, D. Barkur, K. Meier, K. Bock. 소음 합성 데이터를 사용한 신경망을 통한 패치 점 연결의 테르모메카니컬 신뢰성 매개변수 평가 연구, 2023 IEEE 전자 포장 기술 컨퍼런스(EPTC), IEEE, 2023, pp. 751-756. [24] R. Reihanisarsansari, F. Samadifam, A. Salameh, F. Mohammadiazar, N. Amiri, S. Channumsin. 신경망 보조 접근법을 통한 전자 시스템 패치 점 접합의 신뢰성 특성화, *IEEE Access* 10 (2022) 123757-123768. [25] M. Z. Akhtar, M. Schmid, A. Zippelius 및 G. Elger, "LEDs 수명 예측 모델링: SAC305 및 SAC105의 열기계적 시뮬레이션," 2024년 제25회 국제 마이크로전자 및 마이크로시스템에서 열역학, 기계적 및 다물리학적 시뮬레이션 및 실험 컨퍼런스 (EuroSimE), 이탈리아 카타니아, 2024, pp. 1-10, doi: 10.1109/EuroSimE60745.2024.10491530. [26] F. Garofalo, D.B. Butrymowicz, 금속의 크리프 및 크리프 파열에 대한 기초 이론, *Phys. Today* 19 (5) (1966) 100-102. [27] M. Sonali, B. Maind, Ms. Wankar, 인공 신경망의 기본에 관한 연구 논문, *Int. J. Recent Innovation Trends Comput. Commun.* 2 (1) (2014) 96-100.
- [28] O'Shea, K., & Nash, R. (2015). 볼륨 콘벌루션 신경망에 대한 소개. *ArXiv*, abs/1511.08458. [29] Kingma, D.P., & Ba, J. (2014). Adam: 확률적 최적화를 위한 방법. *CoRR*, abs/1412.6980. [30] Rumelhart, D.E., Hinton, G.E., Williams, R.J. (1986). 오류 역전파를 통한 표현 학습. *Nature* 323, 533-536. [31] Shao, Z., Er, M.J., Wang, N. (2016). 최소 사용자 개입을 요구하는 효율적인 leave-one-out 교차 검증 기반 극단 학습 머신(ELOO-ELM), *IEEE Trans. Cybern.* 46 (8), 1939-1951, <https://doi.org/10.1109/TCYB.2015.2458177>. [32] Stephenson, W.T., Broderick, T. (2020). 보장된 교차원 근사 교차 검증, *arXiv*. [33] Pang, Y., Wang, Y., Lai, X., Zhang, S., Liang, P., Song, X. (2023). 모델 추정 및 최적화를 개선하기 위한 강화된 Kriging leave-one-out 교차 검증, *Comp. Methods Appl. Mech. Eng.* 414, 116194, <https://doi.org/10.1016/j.cma.2023.116194>. [34] Chicco, D., Warrens, M.J., Jurman, G. (2021). 회귀 분석 평가에서 결정 계수 R-squared는 SMAPE, MAE, MAPE, MSE 및 RMSE보다 더 정보 제공력이 높다, *PeerJ Comp. Sci.* 7, e623. [35] 정 혼, 오 영, 클래스 활성 맵핑의 개선된 설명을 위한 연구, *arXiv* (2021). <https://arxiv.org/abs/2102.05228>. [36] R. R. Selvaraju, M. Cogswell, A. Das, R. Vedantam, D. Parikh 및 D. Batra, "Grad-CAM: Deep Networks를 통한 그라디언트 기반 로컬화를 이용한 시각적 설명," 2017 IEEE 국제 컴퓨터 비전 컨퍼런스 (ICCV), 이탈리아 베니스, 2017, pp. 618-626, doi: 10.1109/ICCV.2017.74. [37] M. Schmid, A. Zippelius, A. HanB, S. Böckhorst, G. Elger, 자동차 응용 프로그램에서 고출력 LED와 솔더 인터커넥트에 대한 연구: 제 1부 - 초기 특성화, *IEEE Trans. Device Mater. Reliab.* (2022), <https://doi.org/10.1109/TDMR.2022.3152590>. [38] M. Schmid, A. Zippelius, A. HanB, S. Böckhorst, G. Elger, 자동차 응용 프로그램에서 고출력 LED와 솔더 인터커넥트에 대한 연구: 제 2부 - 신뢰성, *IEEE Trans. Device Mater. Reliab.* 23 (3) (2023) 419-429, <https://doi.org/10.1109/TDMR.2023.3300355>. [39] Ping Xu, M. Rauer, M. Kaloudis 및 J. 프란케, "LED 응용 프로그램에서 공기구멍이 솔더 조인트 신뢰성에 미치는 영향 분석을 위한 시뮬레이션 보조 분석," 2016년 제 6회 전자 시스템 통합 기술 컨퍼런스 (ESTC), 그르노블, 2016, pp. 1-5, doi: 10.1109/ESTC.2016.7764726. [40] 데이브록스 등, "열 스트레스 분석을 위한 솔더 합금의 크리프 상수," *SMTA 저널* 26 (2) (2013) pp. 11-20. [41] 슈버트 등, "SnAgCu 및 SnPb 솔더 조인트의 피로 수명 모델: 실험과 시뮬레이션을 통한 평가," 53rd ECTC 2003, pp. 603-610. [42] 아크타르, M.Z., 크라이너, C., 슈미트, M., 짝펠리우스, A., 테츠라프, U., 엘거, G., "FEA 후 처리를 위한 완전 연결 신경망 (FCNN) 기반 검증 프레임워크: SAC 솔더 신뢰성 분석 개선," IEEE, 베를린, 독일, 2024, pp. 1-8, <https://doi.org/10.1109/ESTC60143.2024.10712023>. [43] 카타미노, P., 캐터크, I., 오즈 yilmaz, L., "파킨슨병 손글씨 그림 진단을 위한 딥 러닝-CNN 기반 시스템," IEEE, 이스탄불, 터키, 2018, pp. 1-6, <https://doi.org/10.1109/CEIT.2018.8751879>. [44] 안, S., 리, M.J., 파크, S., 양, H.S., 소, J. (2020). 단순 합성곱 신경망 모델들의 ensemble을 이용한 MNIST 숫자 인식. *ArXiv*, abs/2008.10400. [45] Y. Xie, Y. Luo, H. She 및 Z. Xiang, "추가 계산과 구조 요구사항 없이 신경망 모델 가위," 2023년 제26회 국제 협업 설계 지원을 위한 컴퓨터 지원 워크숍 (CSCWD), 리우데자네이루, 브라질, 2023, pp. 1734-1740, doi: 10.1109/CSCWD57460.2023.10152777.